SESIÓN 1: ÁRBOLES DE DECISIÓN

1. Suponga el siguiente árbol simple T con sólo dos nodos (hojas) terminales. En el nodo raíz se tiene 100 individuos que se dividen en dos nodos hijos de 60 y 40 individuos cada uno. La variable de respuesta indica la compra (No o Si) de un cierto producto:

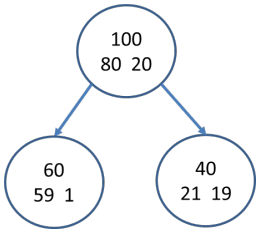

Calcule la reducción de impureza que se obtiene al pasar del nodo padre a los dos nodos hijos.

Teniendo en cuenta que la raíz is No, el nodo hoja izquierdo es No(60), el derecho Si(40), y lo mismo con los valores, No = 80,59,21 y Si = 20,1,19, procedemos a hacer los cálculos.

Impureza nodo 1 = (80/100)*(1-(80/100)) + (20/100)*(1-(20/100)) = 0.32

Impureza nodo 2 = (59/60)*(1-(59/60)) + (1/60)*(1-(1/60)) = 0.032

Impureza nodo 3 = (21/40)*(1-(21/40)) + (19/40)*(1-(19/40)) = 0.498

2. Con el mismo árbol precedente, calcule su coste de mal clasificación $R(T)$.

la mal clasificación (o missclassification o r(t)) de cada nodo se calcula con `r(t)=1-Max(p(j/t))` así que:

```
r1 <- 1-(20/100)
r2 <- 1-(1/60)
r3 <- 1-(21/40)
```

Y la fórmula de R(t) nos dice que es igual a:

```
Rt <- (((0.6)*r2 + (0.4)*r3)/r1)*100
```

Lo que es igual a 97.5

3. Retome los datos del problema *churn*. Se trata ahora de obtener un árbol de decisión que nos permita efectuar predicciones sobre la probabilidad de baja de los clientes. Cargue en R la Liberia *rpart* y obtenga un árbol máximo (cp=0.0001) con crossvalidación (xval=10).

```
> d <- read.csv(file="churn.txt", sep=" ")
> m<-rpart(Baja ~ ., data=d, control=rpart.control( cp = 0.0001,
xval=10))
> printcp(m)
Classification tree:
rpart(formula = Baja ~ ., data = d, control = rpart.control(cp =
1e-04,
    xval = 10))

Variables actually used in tree construction:
 [1] Debito_aff           Nomina               Pension
Total_Plazo          Total_Seguros        Total_Vista
 [7] Total_activo         antig                dif_CC
dif_Hipoteca         dif_Largo_plazo      dif_Libreta
[13] dif_Planes_pension   dif_Plazo            dif_Prest_personales
dif_Seguros          edatcat              oper_ven_Libreta
[19] sexo
```

```
Root node error: 1000/2000 = 0.5

n= 2000
           CP nsplit rel error xerror     xstd
1  0.35300000      0     1.000  1.086 0.022278
2  0.07400000      1     0.647  0.693 0.021281
3  0.02800000      2     0.573  0.591 0.020405
4  0.02450000      3     0.545  0.594 0.020435
5  0.01800000      5     0.496  0.540 0.019854
6  0.01600000      6     0.478  0.521 0.019629
7  0.01500000      7     0.462  0.500 0.019365
8  0.01400000      8     0.447  0.500 0.019365
9  0.01100000      9     0.433  0.482 0.019127
10 0.01000000     10     0.422  0.480 0.019100
11 0.00900000     13     0.392  0.469 0.018948
12 0.00800000     14     0.383  0.468 0.018934
13 0.00700000     15     0.375  0.455 0.018748
14 0.00650000     18     0.354  0.453 0.018719
15 0.00500000     20     0.341  0.448 0.018645
16 0.00450000     23     0.326  0.446 0.018616
17 0.00300000     27     0.308  0.427 0.018326
18 0.00266667     31     0.293  0.415 0.018135
19 0.00250000     34     0.285  0.413 0.018103
20 0.00200000     37     0.276  0.412 0.018087
21 0.00175000     42     0.266  0.412 0.018087
22 0.00166667     46     0.259  0.412 0.018087
23 0.00150000     49     0.254  0.408 0.018021
24 0.00100000     51     0.251  0.412 0.018087
25 0.00050000     59     0.243  0.427 0.018326
26 0.00033333     61     0.242  0.432 0.018403
27 0.00010000     67     0.240  0.435 0.018450
```

4. Determine ahora el árbol óptimo y su valor del *complexity parameter* (cp). Diga cuales son las variables más importantes en la definición del árbol óptimo.

```
> m$cptable = as.data.frame(m$cptable)
> ind = which.min(m$cptable$xerror)
> xerr <- m$cptable$xerror[ind]
> xstd <- m$cptable$xstd[ind]
> i=1
> while (m$cptable$xerror[i] > xerr+xstd) i = i+1
> alfa = m$cptable$CP[i]
> m1 <- prune(m,cp=alfa)
> m1
n= 2000

node), split, n, loss, yval, (yprob)
      * denotes terminal node

   1) root 2000 1000 Baja NO (0.50000000 0.50000000)
     2) Total_Vista< 327.5 1191  419 Baja NO (0.64819479
0.35180521)
       4) dif_Libreta>=-22.045 911  242 Baja NO (0.73435785
0.26564215)
```

```
          8) Total_activo< 793 793  169 Baja NO (0.78688525
0.21311475)
...
```

Según m1, la variable con más importancia es Total_Vista, seguida de dif_Libreta y Total_activo. El análisis da un conjunto de variables más grande, pero estas son las primeras y por las que se hacen las divisiones principales desde la raíz del árbol.

5. Represente gráficamente el árbol óptimo y liste sus reglas de decisión.

```
> install.packages("rpart.plot")
> library("rpart.plot")
> rpart.plot(m1)
```

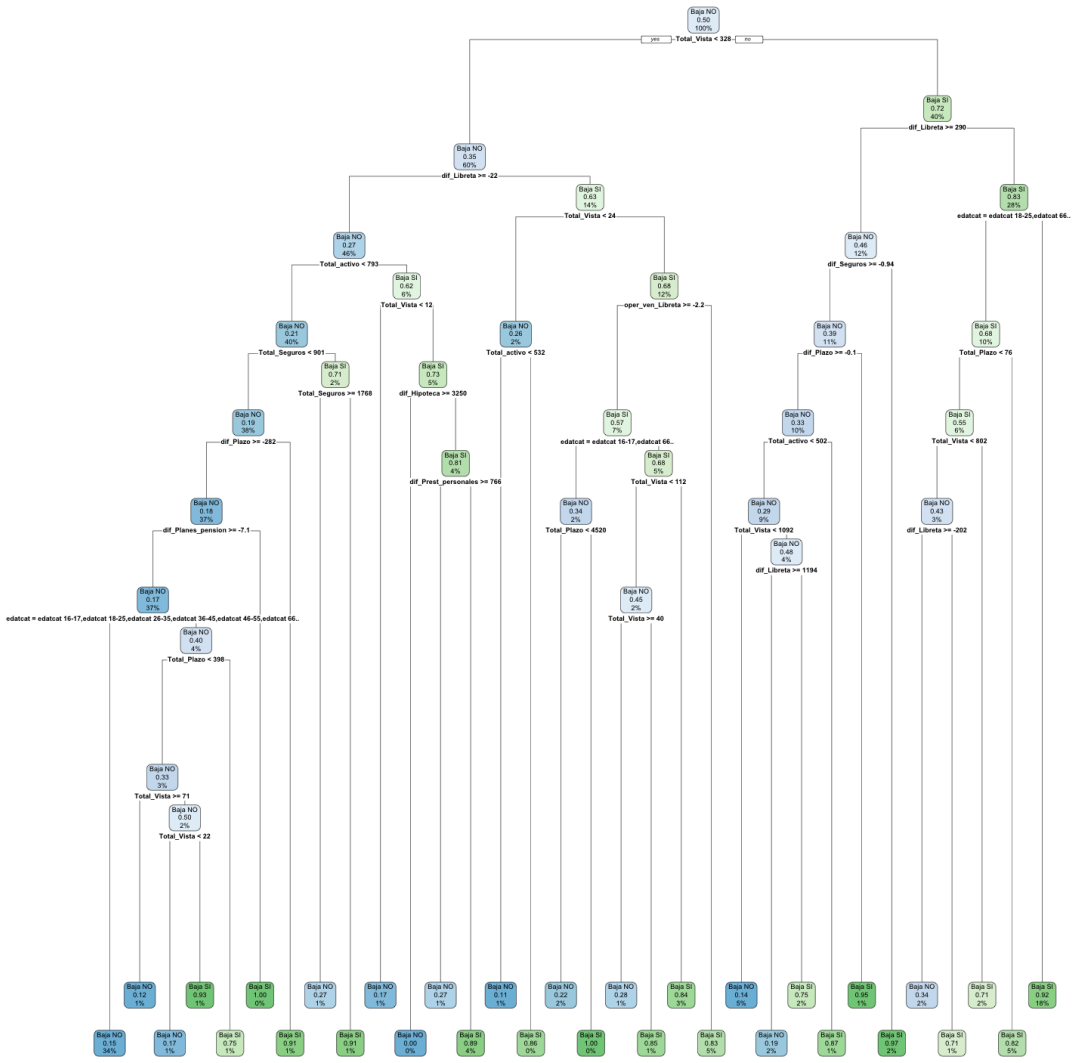


```
library("rattle")
asRules(m1)
Rule number: 89 [Baja=Baja SI cover=7 (0%) prob=1.00]
   Total_Vista< 327.5
   dif_Libreta< -22.05
   Total_Vista>=23.5
   oper_ven_Libreta>=-2.25
```

```
   edatcat=edatcat 16-17,edatcat 66..
   Total_Plazo>=4520

 Rule number: 65 [Baja=Baja SI cover=8 (0%) prob=1.00]
   Total_Vista< 327.5
   dif_Libreta>=-22.05
   Total_activo< 793
   Total_Seguros< 901
   dif_Plazo>=-282.5
   dif_Planes_pension< -7.08

 Rule number: 13 [Baja=Baja SI cover=32 (2%) prob=0.97]
   Total_Vista>=327.5
   dif_Libreta>=289.9
   dif_Seguros< -0.935

 Rule number: 25 [Baja=Baja SI cover=20 (1%) prob=0.95]
   Total_Vista>=327.5
   dif_Libreta>=289.9
   dif_Seguros>=-0.935
   dif_Plazo< -0.1

 Rule number: 1035 [Baja=Baja SI cover=14 (1%) prob=0.93]
   Total_Vista< 327.5
   dif_Libreta>=-22.05
   Total_activo< 793
   Total_Seguros< 901
   dif_Plazo>=-282.5
   dif_Planes_pension>=-7.08
   edatcat=edatcat 56-65
   Total_Plazo< 398
   Total_Vista< 71
   Total_Vista>=21.5
...
```

Y así es como se pueden imprimir todas las reglas. Faltan muchas más que me dejé por copiar.
En ellas se puede ver como cual es el tipo del nodo/hoja, de que pasos se ha llegado hasta ahí y cual es la

6. Las probabilidades de baja no están por fortuna equidistribuidas, sino que la probabilidad de baja es muy inferior (un 5%). Exporte a Excel la tabla de resultados por hoja y pondere estos resultados de acuerdo con las probabilidades a priori mencionadas. Obsérvese que en este caso no utilizamos una muestra test de validación del árbol obtenido (en general deberíamos obtener la predicción del árbol en una muestra independiente (test) y validar la calidad del árbol con los resultados obtenidos en esta muestra test).

```
> m1.leaf=subset(m1$frame, var=="<leaf>",select=c(n,yval2))
> num_leaf = row.names(m1.leaf)
> m1.leaf=data.frame(m1.leaf$n,m1.leaf$yval2)
> names(m1.leaf) =
c("n_train","class_train","n1_train","n2_train","p1_train","p2_trai
n","probnode_train")
```

```
> row.names(m1.leaf) = num_leaf
> m1.leaf=m1.leaf[order(-m1.leaf$p2_train),] # ordering by
decreasing > positive probabilities

> install.packages('xlsx')
> install.packages('rJava')
> install.packages('xlsxjars')
> library(xlsx)

write.xlsx(m1.leaf, "resultats.xlsx")
```

	A	B	C	D	E	F	G	H	I
1		n_train	class_train	n1_train	n2_train	p1_train	p2_train	probnode_train	
2	65	8	2	0	8	0	1	0,004	
3	89	7	2	0	7	0	1	0,0035	
4	13	32	2	1	31	0,03125	0,96875	0,016	
5	25	20	2	1	19	0,05	0,95	0,01	
6	1035	14	2	1	13	0,071429	0,928571	0,007	
7	35	23	2	2	21	0,086957	0,913043	0,0115	
8	33	11	2	1	10	0,090909	0,909091	0,0055	
9	79	74	2	8	66	0,108108	0,891892	0,037	
10	49	15	2	2	13	0,133333	0,866667	0,0075	
11	21	7	2	1	6	0,142857	0,857143	0,0035	
12	181	13	2	2	11	0,153846	0,846154	0,0065	
13	91	57	2	9	48	0,157895	0,842105	0,0285	
14	23	103	2	17	86	0,165049	0,834951	0,0515	
15	7	560	2	94	466	0,167857	0,832143	0,28	
16	259	12	2	3	9	0,25	0,75	0,006	
17	195	40	2	10	30	0,25	0,75	0,02	
18	180	29	1	21	8	0,724138	0,275862	0,0145	
19	34	11	1	8	3	0,727273	0,272727	0,0055	
20	78	11	1	8	3	0,727273	0,272727	0,0055	
21	88	37	1	29	8	0,783784	0,216216	0,0185	
22	194	37	1	30	7	0,810811	0,189189	0,0185	
23	18	23	1	19	4	0,826087	0,173913	0,0115	
24	1034	18	1	15	3	0,833333	0,166667	0,009	
25	128	670	1	571	99	0,852239	0,147761	0,335	
26	96	105	1	90	15	0,857143	0,142857	0,0525	
27	516	26	1	23	3	0,884615	0,115385	0,013	
28	20	27	1	24	3	0,888889	0,111111	0,0135	
29	38	10	1	10	0	1	0	0,005	
30									
31								1	

7. Obtenga gráficamente las curvas de concentración y ROC correspondientes.

```
> pred_test = as.data.frame(predict(m1, newdata=d[-
learn,],type="prob"))
> pred <- prediction(pred_test$"Baja SI", d$Baja[-learn])
> roc <- performance(pred,measure="tpr",x.measure="fpr")
> plot(roc, main="ROC curve")
```

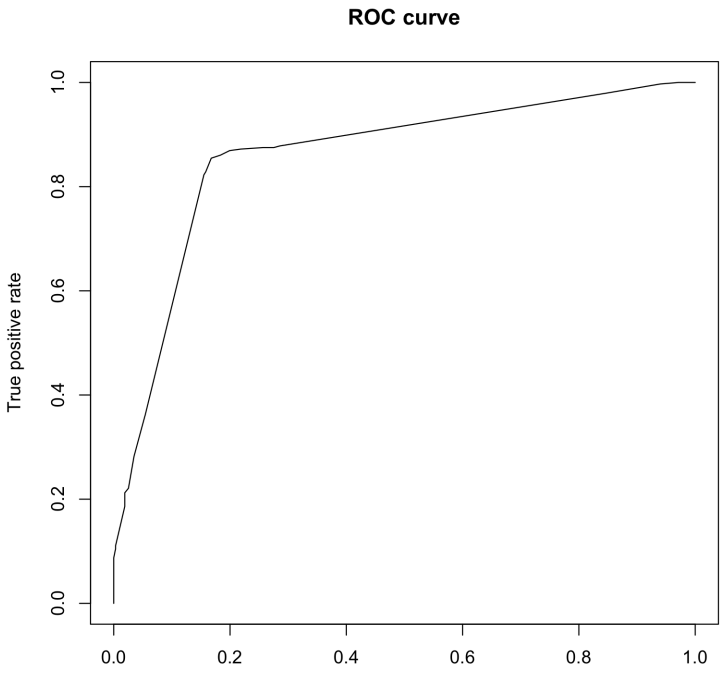


```
> con <- performance(pred,measure="tpr",x.measure="rpp")
```

```
> plot(con, main="Concentration curve")
```

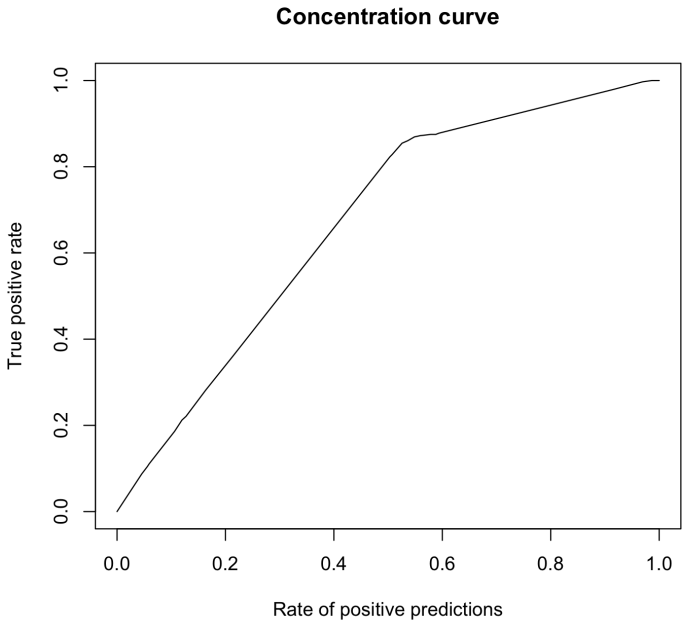

8. Decida un umbral de decisión para la predicción de “baja” y obtenga el “error_rate”, la precisión en la predicción positiva, la precisión en la predicción negativa, el promedio de ambas precisiones y el Recall asociado al umbral escogido.